

به نام خدا

درس مبانی یادگیری عمیق

گزارش پروژه‌ی پایانی

استاد: دکتر داوودآبادی

دستیاران آموزشی: مرتضی حاجی آبادی، مهدی خورشید
دانشگاه علم و صنعت ایران - دانشکده مهندسی کامپیوتر

نیم‌سال اول تحصیلی ۱۴۰۳ - ۱۴۰۴



ردیف	نام و نام خانوادگی	شماره‌ی دانشجویی
1	محمد درمانلو	99521262

موضوع:

بازیابی ویدیو براساس توصیف متنی صحنه‌ی ورودی

هدف این پروژه Fine-Tune کردن مدل CLIP با توضیحات فارسی می‌باشد، تا بتوان از بین مجموعه‌ای از ویدیوهای انتخابی با توجه به توضیحات فارسی داده شده، ویدیوی مورد نظر را پیدا کرد.

مجموعه داده مورد استفاده برای این پروژه، مجموعه داده Flickr30k است. این مجموعه داده شامل ۳۰۰۰۰ تصویر به همراه ۵ توضیح به زبان انگلیسی برای هر تصویر است. تصاویر این مجموعه به صورت General می‌باشند و مختص به یک موضوع خاص نیستند. برای استفاده از توضیحات این مجموعه داده، ابتدا تمام توضیحات توسط مدل‌های ترجمه، از انگلیسی به فارسی ترجمه شدند.

در ابتدا سعی شد که با استفاده از داده‌های مجموعه داده Flickr8k مدل را fine-tune کنیم. پس از آموزش مدل به میزان ۱۰ epoch بر روی داده‌های فارسی به نتایج نسبتاً مطلوبی رسیدیم. سپس تصمیم گرفته شد که مدل را بر روی مجموعه داده Flickr30k آموزش بدیم. در مسیر آماده سازی داده‌های مربوط به این مجموعه داده از آنجا که در حدود ۱۵۰ هزار توضیح انگلیسی باید به فارسی ترجمه می‌شد و با توجه به کمبود منابع، مجبور به تقسیم بندی این داده‌ها به ۵ دسته مختلف شده و در نهایت هر دسته را به صورت موازی بر روی یک runtime در colab اجرا کردیم.

۲ پیش پردازش داده ها

برای استفاده از مدل CLIP ابتدا نیاز داریم که تصاویر و متن‌های ورودی را به حالتی که مدل آنها را می‌پذیرد تبدیل بکنیم. برای این کار ابتدا تصاویر را با استفاده از Processor از قبل آموزش دیده CLIP پردازش کرده و Image Transform هایی را بر روی آنها اعمال می‌کنیم. به عنوان مثال ابعاد تصاویر ورودی باید ۲۲۴ در ۲۲۴ باشد. همچنین برای متن‌ها هم از Processor از قبل آموزش دیده CLIP استفاده کرده و متن‌ها را با استفاده از آن Tokenize می‌کنیم.


در نهایت مجموعه داده ما آماده استفاده بر روی مدل کلیپ است.

۳ انتخاب مدل

برای تسک image retrieval، مدل های مختلفی قابل استفاده هستند که از آنها می توان به Swin، ViT و CLIP اشاره کرد.

برای این پروژه از مدل CLIP استفاده شده است. این مدل متشکل از دو بخش مجزا برای encoding تصویر و متن است. خروجی این دو بخش با یکدیگر مقایسه شده تا میزان شباهت آن ها بررسی شود. در هر batch ورودی تعدادی تصویر و به همان تعداد توضیح متناظر با هر تصویر به encoder ها داده می شود و در نهایت ماتریسی از میزان شباهت یک به یک این تصاویر و توضیحات به دست می آید. خروجی ایده آل برای مدل حالتی است که ماتریس خروجی یک ماتریس همانی باشد.

یکی از دلایل انتخاب این مدل، embedding تصاویر و متن ها به یک فضای مشترک است که این موضوع استفاده از natural language برای باز گرداندن تصاویر را آسان می کند. همچنین این مدل از آنجایی که بر مجموعه داده ی گوناگونی آموزش دیده است، قابلیت استفاده در تسک های zero-shot و few-show را هم دارد.



۴ اقدامات انجام شده

پس از آماده سازی داده‌ها، مجموعه داده‌ها را به مجموعه‌های آموزش و تست تقسیم بندی کردیم و 6 درصد از داده‌ها را برای تست در نظر گرفتیم. پس از این مرحله شروع به آموزش مدل کردیم. با توجه به حجم بالای داده‌ها و حجم بالای پارامترها در مدل، اجرای آموزش به منابع زیادی احتیاج داشت که بیشتر از محدودیت‌های runtime های colab بود. در نهایت فرایند آموزش مدل را با تقسیم کردن به بخش‌های کوچکتر در runtime های مختلف اجرا کردیم. به این صورت که هر runtime، مدل خروجی runtime قبلی را آموزش می‌داد.

برای ارزیابی مدل در حین آموزش و پس از آموزش از معیار AUC استفاده کردیم این معیار به خوبی مرتبط بودن و یا مرتبط نبودن هر توضیح به تصاویر را اندازه‌گیری می‌کند. برای استفاده از این معیار در حین آموزش، پس از هر epoch بخشی از داده‌های validation را انتخاب کرده و سپس تشابه هر یک از توضیحات را با تمامی تصاویر مقایسه می‌کنیم. در نهایت بردار به دست آمده را به همراه بردار ground truth که به صورت یک وکتور one-hot که تنها در مکان تصویر متناظر با توضیح برابر با یک است به تابع AUC داده و معیار را محاسبه می‌کنیم.


پس از آموزش مدل و به دست آوردن نتایج و خروجی مناسب به پیاده‌سازی API و UI پرداختیم. برای پیاده‌سازی API از FastAPI و برای پیاده‌سازی UI از Streamlit استفاده کردیم. در نهایت کاربر می‌تواند با استفاده از یک اینترفیس

ویدیوهای خود را به دیتابیس اضافه کرده و بر اساس توضیحات ورودی ویدیوهای خود را retrieve کند.


۵ ارزیابی مدل

برای

ارزیابی مدل از معیار AUC استفاده شده است این معیار مرتبط بودن و یا مرتبط نبودن هر توضیح ا مجموعه تصاویر را می‌سنجد. برای استفاده از این معیار ابتدا بخشی از داده‌های validation را انتخاب کرده و سپس تشابه هر یک از توضیحات را با تمامی تصاویر مقایسه می‌کنیم و در نهایت بردار به دست آمده را با بردار ground-truth قایسه می‌کنیم. مدل بر روی مجموعه داده‌های Flicker30k برای هفت epoch آموزش دید که مقدار loss پس از هر epoch به شکل نمودار زیر است.



همانطور که در نمودار مشخص است پس از epoch چهارم مدل دچار overfit شده و عملکرد مدل بر روی داده‌های validation افت می‌کند. س می‌توان گفت بهترین نسخه مدل نسخه بعد از epoch چهارم است. پس از هر epoch مقدار AUC score را برای مدل روی داده‌های validation محاسبه کردیم که مقدار آنها به شکل نمودار زیر است



همانطور که در نمودار مشخص است مشابه نمودار **loss** می‌بینیم که پس از **epoch** چهارم مدل پیشرفت چندانی نداشته است و حتی افت هم کرده است.

همچنین مشخص است که عملکرد نسبتاً مطلوبی داشته است چرا که مقدار **AUC** برای مدل کلیپ **fine-tune** نشده بر روی داده‌های انگلیسی برابر با خط قرمز بوده است که مدل **fine-tune** ما بر روی داده‌های فارسی عملکرد نزدیکی به این مدل داشته است.

مثال هایی از عملکرد صحیح مدل:

Search for Relevant Videos

Enter search query

یک مرد در حال رانندگی

Retrieve Videos

Top Retrieved Videos:

Video: uploaded_videos/generalVid8.mp4, Similarity: 0.7580



Video: uploaded_videos/generalVid1.mp4, Similarity: 0.7307



Search for Relevant Videos

Enter search query

مردم در یک سالن کنسرت

Retrieve Videos

Top Retrieved Videos:

Video: uploaded_videos/generalVid12.mp4, Similarity: 0.7325



Video: uploaded_videos/generalVid1.mp4, Similarity: 0.6904



مثالی از عملکرد اشتباه مدل:

Search for Relevant Videos

Enter search query

پنگوئن

Retrieve Videos

Top Retrieved Videos:

Video: uploaded_videos/generalVid1.mp4, Similarity: 0.7371



Video: uploaded_videos/generalVid4.mp4, Similarity: 0.7366



به طور کلی در شرایطی که توضیح ورودی شامل تعداد کلمات کمی باشد و یا شامل کلماتی باشد که در دیتاست
Flicker30k تعداد تکرار خوبی نداشته باشند، عملکرد مدل افت خواهد کرد. این به این دلیل است که مدل pre-train شده
ی CLIP بر روی داده‌های فارسی آموزش ندیده است و بر روی حجم زیادی از داده‌های غیر فارسی آموزش دیده است. این
باعث می‌شود که این مدل بر روی زبان‌های غیر فارسی مانند انگلیسی رنج بسیار بزرگتری از کلمات را پوشش دهد.

۶ بخش امتیازی

یکی از بخش‌های امتیازی پروژه پیاده‌سازی API و UI مناسب برای مدل بود. برای این مورد از ۳۰ FastAPI و Streamlit استفاده کردیم تا کاربر بتواند با استفاده از یک اینترفیس فایل‌های خود را آپلود کرده و سپس با توضیحات فارسی یا انگلیسی ویدیوها را retrieve کند.

Video Retrieval System

Upload Videos

Choose video files



Drag and drop files here

Limit 200MB per file • MP4, AVI, MOV, MPEG4

Browse files

Process Video Frames

Process Frames

Search for Relevant Videos

Enter search query

یک مرد در حال رانندگی

Retrieve Videos

۷ مراجع

<https://openai.com/index/clip/>

ChatGPT